

Proyecto 4 - Clasificación de señales ECG

Catalina Guerra Fernandez, Angie Tovar Bohorquez, Juan Esteban Campillo

Universidad de Antioquia

Diciembre 1, 2024



1. Hacer un resumen de la sección extracción de características (Features extraction) y discutir desde el artículo u otras referencias como se hace cuando desaparecen ciertas formas de ondas en el complejo PQRS debido a alguna enfermedad

Primero se comienza evaluando los distintos métodos que se han usado para la extracción de características, primero se mencionan las redes neuronales profundas, sin embargo este método requiere de un número muy grande de datos y de neuronas, llegando a tener un tiempo considerable de computación, por lo que se evalúa la extracción de características manual, sin embargo estas características no proporcionan suficiente información para lograr clasificar una arritmia. En el proyecto se usó un método nuevo que corresponde a la clasificación multicapa para la selección de características, en la cual se distribuye la selección de características en 11 etapas diferentes, para la primera etapa se tuvieron en cuenta 11 características iniciales para realizar la extracción de las señales ECG, estas fueron las más básicas correspondientes a la duración del complejo QRS, la frecuencia ventricular, entre otros. Conforme se avanzaba en la etapa se avanzaba tanto en complejidad como en cantidad de características extraídas, en la segunda etapa se evalúan las características estadísticas como el promedio y la varianza entre picos, esto para evaluar la variabilidad de la señal, luego en la etapa 3 se extraen las características del grupo 1, algunas del grupo 2 y la prominencia del complejo QRS, esto para identificar la morfología de las señales, desde la etapa 4 a la 7 se extraen más características sobre la variabilidad en los picos y valles de las ondas (como las diferencias en la altura, el ancho y la prominencia de los picos y valles). Además, se calcula la diferencia de ubicación entre picos y valles, en la etapa 8 y 9 se realiza extracción de análisis en frecuencia en los cuales se evalúan los ratios de diferencias entre alturas de picos, finalmente en el grupo 10 y 11 se toman los valores de las 12 derivaciones obteniendo 39.830 características.

En el artículo se menciona una estrategia común correspondiente la extracción manual de características, tales como las magnitudes de los picos, su duración, la distancia entre picos y la variabilidad de los 4 componentes de los latidos P, Q, T y QRS. Sin embargo estas

características no proporcionan suficiente información para lograr clasificar de manera precisa los tipos de arritmia, por ejemplo cuando disminuye la amplitud de una onda p normal debido a la distorsión por la fibrilación auricular. Para estos casos la mejor forma de seguir es determinando la mayor cantidad de características que me permita hacer la distinción, como lo es con el uso de redes neuronales profundas, o ahondar en la fisiopatología que es difícil de detectar y determinar la característica que es difícil de ver, en el caso de la onda p que esconde el complejo QRS, se ve que los intervalos R-R tienen alta variabilidad debido a la irregularidad de este complejo por lo que se hace un análisis de características basadas en intervalos [1].

2. De acuerdo a los resultados del proyecto 3 usar la mejor base de datos y justificar la selección.


En el proyecto tres, los valores de las frecuencias mostraron una mayor dispersión, lo que indicaba una variabilidad más alta en las frecuencias de máxima potencia. Esto sugiere que el proceso de filtrado no fue tan eficiente como el realizado en el proyecto dos. Por esta razón la base de datos que se utilizará será la proyectos dos.

3. Herramientas computacionales. Hacer un mini tutorial del uso de la herramienta NeuroKit orientado al análisis de señales ECG

Se elaboró un manual que será adjuntado como archivo PDF en la entrega.

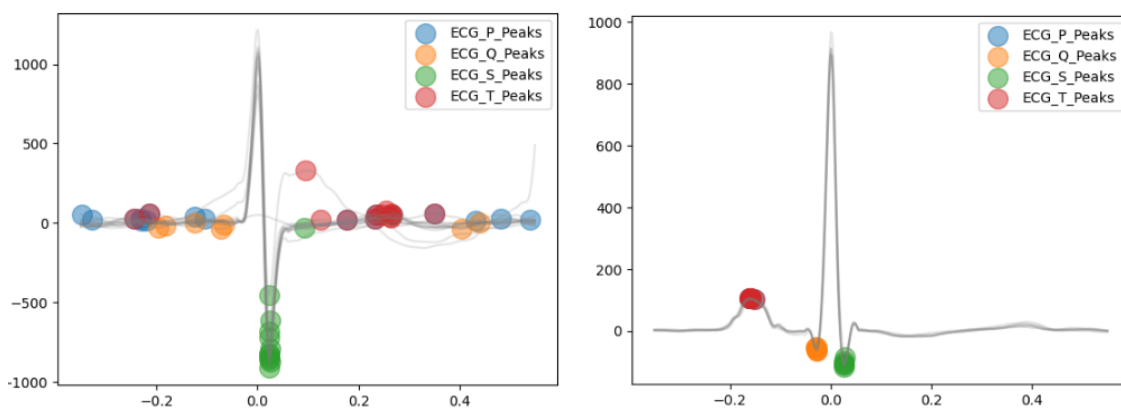
4. Escoger diferentes señales de la base de datos del punto 2 y aplicar el tutorial del punto 3

Se seleccionaron tres señales aleatorias correspondientes a bradicardia sinusal y fibrilación auricular. Luego, se aplicó la función `peaks` para identificar los picos R. Los resultados obtenidos a partir de esta función fueron procesados mediante la función `delineate`, utilizando el método `peaks` y configurando los parámetros `show_type` como `peaks` y `bounds` como `P`. Uno de los resultados obtenidos se muestra en la Gráfica 1.



Gráfica 1. Complejo PQS y T para fibrilación auricular y bradicardia sinusal respectivamente, con el método peaks

Posteriormente, se repitió el mismo procedimiento, pero cambiando el método a CWT y configurando el parámetro *show_type* en peaks y bound en R. Los resultados obtenidos se presentan en la Gráfica 2



Gráfica 2. Complejo PQS y T para fibrilación auricular y bradicardia sinusal respectivamente, con el método CWT

Al observar las gráficas, se evidencia que, dependiendo del método utilizado, la detección de los picos de las ondas puede variar. Por ejemplo, en el caso de bradicardia sinusal, el primer método clasifica la primera onda como P, mientras que el segundo la identifica como T. Esto se debe a las diferencias en la sensibilidad y precisión de cada técnica para detectar los picos en las señales, lo que afecta la localización exacta de estos puntos. Es importante destacar que estas funciones no solo permiten graficar las señales, sino que también devuelven los valores de los picos (P, Q, S, T) y los puntos de inicio y final de las ondas P y T. Toda esta información se presenta en forma de un diccionario.

5. Con las características que extrae el neurokit y las discutidas en el punto 1 generar

un conjunto de características para el presente trabajo. Incluir la característica de frecuencia de potencia máxima del Proyecto 3 . No incluir más de 15 características ni menos de 5, justificar la selección.

5.1. Promedio de los intervalos RR

Se trata de la distancia entre dos ondas R consecutivas. Estas ondas R son las que indican la contracción del miocardio en un electrocardiograma. Específicamente, se trata de la distancia o tiempo existente entre dos latidos del corazón [2]. Es importante porque la variación en el tiempo que transcurre entre los intervalos RR indica la variabilidad de la frecuencia cardíaca. Su aumento se considera un factor protector para el corazón y su medición podría ser una herramienta predictiva temprana o diagnóstica en enfermedades cardiovasculares[3].

5.2. Varianza de los intervalos RR

Se refiere a una medida estadística que cuantifica la dispersión o la variabilidad de los intervalos RR con respecto a su media [4]. Es importante porque proporciona una medida clave sobre la irregularidad de los latidos del corazón

5.3. Número de intervalos RR

Hacer referencia a la cantidad de intervalos RR que hay en determinado periodo de tiempo. Este es útil para calcular la frecuencia cardíaca

5.4. Frecuencia Cardíaca ventricular

La frecuencia cardíaca es el número de veces que se contrae el corazón durante un minuto, específicamente, la ventricular indica la frecuencia de los complejos QRS [5]. Su importancia radica en que revisando la literatura, algunos ensayos clínicos han sugerido que una frecuencia ventricular alta se asocia con un mayor riesgo de insuficiencia cardíaca (IC), entre los que se encuentra, la fibrilación auricular [6].

5.5 Frecuencia cardíaca auricular

La frecuencia auricular, derivada de los intervalos PP en los electrocardiogramas (ECG), refleja la frecuencia de las despolarizaciones auriculares [7]. La dispersión de la onda P, se asocia con factores de riesgo de fibrilación auricular, como enfermedad cardiovascular, hipertensión e hipertrofia ventricular izquierda [8].

5.6 Duración de la onda P

En la onda P se aprecia la despolarización de las aurículas, su duración normal debe ser de menos de 120 ms [9]. La interpretación de la onda P en el ECG es fundamental para el diagnóstico de numerosas condiciones cardíacas, por ejemplo, la presencia de ondas P irregulares puede ser un indicio de la fibrilación auricular [10].

5.7 Frecuencia de máxima potencia

Es la frecuencia en la que se concentra la mayor parte de la energía de una señal. En el caso de un ECG, esta frecuencia corresponde al componente más significativo del espectro de potencia de la señal. Por ejemplo, durante la fibrilación auricular, la frecuencia dominante está relacionada con las ondas auriculares (ondas f) rápidas e irregulares.

6. Código y análisis de resultados, donde se discutan por los menos tres diferentes arquitecturas de red y las matrices de confusión obtenidas, de una red neuronal que permita la clasificación de las dos patologías cardíacas.

Se analizaron 3 distintas arquitecturas de redes neuronales, teniendo un modelo intermedio en complejidad, uno más complejo y uno más sencillo, evaluando la matriz de confusión en cada uno para poder determinar su precisión, recall y sensibilidad.


Los hiperparámetros que variaron corresponden al número de capas ocultas, función de activación, optimizador o solver y número de iteraciones.

Arquitectura 1:

Para la arquitectura 1 se hizo uso de un número de capas ocultas de (8,8,8), esto significa que tengo 3 capas, cada una con 8 neuronas, se usó una función de activación ReLU (Rectified Linear Unit), la cual toma la parte en la cual la función tiene la derivada positiva y lo vuelve 1, se tomó esta ya que es la más usada en el ámbito de las redes neuronales, un solver adam y un número de iteraciones de 1000.

```
mlp = MLPClassifier(hidden_layer_sizes=(8,8,8), activation='relu', solver='adam', max_iter=1000)
```

imagen 1 Arquitectura 1 de redes neuronales.



Gráfica 3 Matriz de confusión de para trining y testing para la arquitectura 1 de una red neuronal.

Para el análisis de los resultados obtenidos se tienen en cuenta 3 métricas principales obtenidas a partir de la matriz de confusión, para esto se toma en cuenta la definición de matriz de confusión, en la cual el primer cuadro hace referencia a los verdaderos positivos (TP), es decir, aquellos valores de fibrilación que el modelo logró predecir correctamente, el cuadro superior derecho hace referencia al Falso negativo (FN), es decir, aquellos valores que correspondían a fibrilación, pero el modelo clasificó como bradicardia, el cuadrante inferior izquierdo es Falso positivo (FP), aquellos valores que el modelo clasificó como fibrilación pero su valor real era bradicardia, y el último cuadro corresponde a Verdadero negativo (TN), el cual se refiere a aquellos valores de bradicardia que el modelo clasificó correctamente.

La precisión se define como la proporción de casos clasificados como positivos que realmente son positivos.

$$Precisión = \frac{TP}{TP+FP}$$

La sensibilidad es aquella que mide la tasa de casos positivos reales que fueron clasificados correctamente.

$$Recall = \frac{TP}{TP+FN}$$

Teniendo esto en cuenta, en el contexto médico es de vital importancia evitar tanto falsos negativos como falsos positivos, ya que un diagnóstico de fibrilación para una persona que tenga bradicardia puede llevar a que el tratamiento provoque daños irreversibles e incluso la muerte, es por esto que la métrica para determinar el mejor modelo en el proyecto es F1-Score, ya que combina tanto como precisión como sensibilidad, obteniendo que si se tiene un valor alto, se evita tanto falsos positivos como falsos negativos.

$$F1 - Score = 2 * \frac{precision * sensibilidad}{precision + sensibilidad}$$

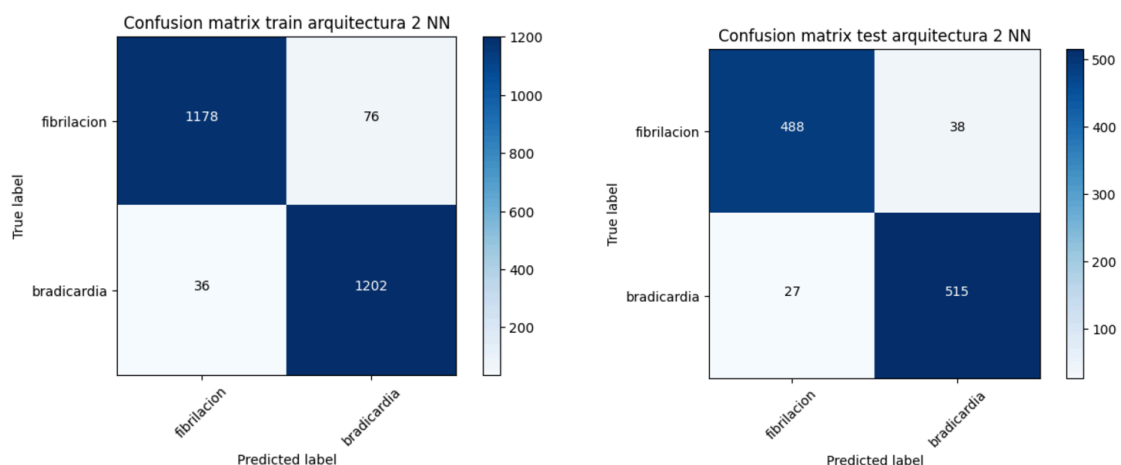
En el caso de la arquitectura 1, el valor de F1 obtenido fue de aproximadamente un 98.6%, indicando un alto número de precisión y a su vez una baja taasa tanto de falsos negativos como positivos.

Arquitectura 2:

Para la arquitectura 2 se evaluó un modelo más complejo, se hizo uso de un número de capas ocultas de (32,16,8,4), aumentando tanto el número de capas como el número de neuronas con respecto a la arquitectura, se usó una función de activación tanh (Tangente hiperbólica), otra función también muy usada, mostrando un mejor rendimiento que la sigmoide ya que evalúa entre -1 y 1, un solver sgd y un número de iteraciones de 2000.

```
mlp2 = MLPClassifier(hidden_layer_sizes=(32,16,8,4), activation='tanh', solver='sgd', max_iter=2000)
```

imagen 2 Arquitectura 2 de redes nueronales.



Gráfica 4 Matriz de confusión de training y testing para la arquitectura 2 de una red neuronal.

En el caso de la arquitectura 2, al ser un modelo mucho más complejo, se demora un poco más en entrenar el modelo, y se espera que el F1 score tenga una mejor relación entre precisión y sensibilidad.


En este caso el F1 obtenido es del 94%, se observa una disminución a pesar del aumento de los hiperparámetros, esto puede ser debido al sobreajuste durante el entrenamiento que suele ser común cuando se aumenta el número de iteraciones, dando como resultado una disminución con los datos de testeo.

Arquitectura 3:

Para la arquitectura 3 se evaluó un modelo más simple, ya que al analizar los dos modelos anteriores, vemos que las métricas siguen teniendo buenos números, y al hacer más sencillo el modelo, se puede mejorar el tiempo y capacidad de procesamiento, se hizo uso de un número de capas ocultas de (4,4), disminuyendo tanto el número de capas como el número de neuronas con respecto a las arquitecturas 1 y 2, se usó una función de activación logistic, un solver adam y un número de iteraciones de 1000.

```
mlp3 = MLPClassifier(hidden_layer_sizes=(4,4), activation='logistic', solver='adam', max_iter=1000)
```

imagen 3 Arquitectura 3 de redes nueronales.



Gráfica 5 Matriz de confusión de training y testing para la arquitectura 3 de una red neuronal.

En este caso el modelo al ser el más sencillo de todos fue el que menos tiempo tardó en procesar, el calculo del F1-Score dio un valor del 94%, muy parecido al valor obtenido para la arquitectura compleja.

Al analizar las 3 métricas evaluadas en los conjuntos de pruebas para cada una de las 3 arquitecturas, se analiza que la mejor arquitectura es una intermedia, que no posea hiperparámetros tan complejos que produzca un sobreajuste y genere un modelo muy complejo que requiera mayor cantidad de almacenamiento y tiempo de procesamiento o parámetros tan sencillos que no se ajuste correctamente a la tendencia de los datos.

7. Consultar cómo funciona, realizar y discutir un ejemplo con los datos, del algoritmo de K means y máquinas de soporte vectorial (SVM).

7.1 K means

Es un algoritmo de agrupación que utiliza centroides, donde se mide la distancia entre cada punto de datos y un centroide para asignarlo a un grupo. Su propósito es determinar el número K de grupos en el conjunto de datos. Este proceso es iterativo, donde los puntos se asignan gradualmente a los grupos, formándose en función de características similares.

1. Elección del número de clústeres: se define el número K de clusters en los que se agruparán los datos.
2. Inicializando centroides: el centroide es el centro de un grupo, pero inicialmente se desconoce el centro exacto de los puntos de datos, por lo que seleccionamos puntos de datos aleatorios y los definimos como centroides para cada grupo.
3. Asignar puntos de datos al clúster más cercano: ahora que los centroides están inicializados, el siguiente paso es asignar los puntos de datos X_n a su centroide de grupo más cercano C_k . En este paso, primero se calcula la distancia entre el punto de datos X y el centroide C utilizando la métrica de distancia euclidiana.

Después, se elige el grupo de puntos de datos donde la distancia entre el punto de datos y el centroide sea mínima.


4. Reinicializar centroides: se calcula el promedio de todos los puntos de datos de ese grupo.

Se siguen repitiendo los pasos 3 y 4 hasta que se tengan centroides óptimos y las asignaciones de puntos de datos a los grupos correctos ya no cambien [11].

```
k_means = KMeans(n_clusters=2, random_state=42)
```

```
k_means.fit(X_train)  
test_labels = k_means.predict(X_test)
```

imagen 4 Aplicación de K-means con los datos de ejemplo.



Gráfica 6 Matriz de confusión de testing para k-means

En la matriz de confusión se observa que los aciertos por parte del modelo son muy pocos, dando muchos falsos positivos y falsos negativos.

K-means se trata de un algoritmo de clasificación no supervisado, es decir agrupa los datos en clusters sin usar etiquetas, dividiendo en grupos que tengan características similares, esto es útil para identificar patrones como agrupar marcadores genéticos o caracterizar el comportamiento de un paciente, sin embargo en nuestro caso tenemos conocimiento de las salidas, fibrilación auricular y bradicardia, esto hace que el algoritmo k-means no sea el modelo adecuado, en este caso un algoritmo supervisado se ajustaría mejor y generaría mejores predicciones.

7.2 Máquinas de soporte vectorial

SVMs ha resultado ser uno de los mejores clasificadores para un amplio abanico de situaciones, por lo que se considera uno de los referentes dentro del ámbito de aprendizaje estadístico y machine learning. Este método de clasificación-regresión originariamente se desarrolló como un método de clasificación binaria, pero su aplicación se ha extendido a problemas de clasificación múltiple y regresión. Su uso se fundamenta en el Maximal Margin Classifier, que a su vez, se basa en el concepto de hiperplano.

En un espacio p -dimensional, un hiperplano se define como un subespacio plano y afín de dimensiones $p-1$. En un espacio de dos dimensiones, el hiperplano es un subespacio de 1 dimensión, es decir, una recta. La definición matemática de un hiperplano, en el caso de p

dimensiones, se describe acorde a la ecuación de una recta.

Si la distribución de las observaciones es tal que se pueden separar linealmente de forma perfecta en las dos clases (+1 y -1), entonces, un hiperplano de separación cumple que:

$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p > 0, \text{ si } y_i = 1$$
$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p < 0, \text{ si } y_i = -1$$


Bajo este escenario, el clasificador más sencillo consiste en asignar cada observación a una clase dependiendo del lado del hiperplano en el que se encuentre. Es decir, la observación x^* se clasifica acorde al signo de la función. Si $f(x^*)$ es positiva, la observación se asigna a la clase +1, si es negativa, a la clase -1. Además, la magnitud de $f(x^*)$ permite saber cómo de lejos está la observación del hiperplano y con ello la confianza de la clasificación.

Se selecciona como clasificador óptimo al que se conoce como *maximal margin hyperplane* o hiperplano óptimo de separación, que se corresponde con el hiperplano que se encuentra más alejado de todas las observaciones de entrenamiento. Sin embargo, este tiene poca aplicación práctica, ya que rara vez se encuentran casos en los que las clases sean perfecta y linealmente separables. Por esta razón, es preferible crear un clasificador basado en un hiperplano que, aunque no separe perfectamente las dos clases, sea más robusto y tenga mayor capacidad predictiva al aplicarlo a nuevas observaciones (menos problemas de overfitting). Esto es exactamente lo que consiguen los clasificadores de vector soporte, también conocidos como soft margin classifiers o Support Vector Classifiers. El método de Máquinas Vector Soporte (SVM) se puede considerar como una extensión del Support Vector Classifier obtenida al aumentar la dimensión de los datos[12].

```
clf = svm.SVC(kernel='rbf')
clf.fit(X_train, y_train)

yhat = clf.predict(X_test)
```

imagen 5 Ejemplo de uso de modelo de SVM.



Gráfica 7 Matriz de confusión de testing para SVM

En la matriz de confusión se observa que las predicciones en el conjunto de prueba son buenas, dando como resultado una alta precisión, esto es debido a que se trata de un algoritmo supervisado, ideal para clasificación binaria con outputs conocidos.

8. Consultar por lo menos tres equipos comerciales traen ya incorporados algoritmos de ayuda diagnóstica a partir de señales ECG y discutir brevemente las funcionalidades desde la teoría vista en el curso.

8.1 Zio XT (iRhythm Technologies)



Se trata de un servicio para monitoreo cardíaco ambulatorio, diseñado específicamente para detectar arritmias en personas que presentan síntomas poco frecuentes, con intervalos de 24 horas o más. El sistema incluye el parche Zio y el informe asociado.

El parche Zio es un dispositivo inalámbrico de ECG que se adhiere a la piel en la parte superior izquierda del pecho, permitiendo su uso continuo durante un periodo de 14 días. Durante ese tiempo, el usuario puede llevar a cabo sus actividades cotidianas, como ducharse o bañarse, ya que el dispositivo es resistente al agua. Al finalizar el monitoreo, el parche se retira y se envía a la empresa. Una vez recibido, los datos del ECG son analizados por algoritmos de inteligencia artificial, y los resultados se resumen en un informe que se envía digitalmente al médico del paciente[13].

8.2 NEO ECG T180 - LEPU Medical



Es un electrocardiógrafo de inteligencia artificial con sistema de análisis y diagnóstico integral de alta precisión con una velocidad de análisis de 1 segundo. Brinda soporte para la detección automática de marcapasos y etiquetado, análisis rr, HRV, patrón de eventos ECG. Se proporcionan cuatro modos de muestreo: pre - muestreo, muestreo en tiempo real, muestreo periódico y muestreo de activación. Con el uso de un algoritmo avanzado de ECG, permite análisis automáticos que proporcionan resultados de diagnóstico precisos [14].

8.3 Cardiógrafo PageWriter TC30 - Phillips



Cuenta con un algoritmo ECG Philips DXL que proporciona interpretaciones ECG líderes del sector y un conjunto de ayudas avanzadas para el diagnóstico de STEMI (infarto agudo de miocardio con elevación del segmento ST) para proporcionar una interpretación del ritmo y la morfología en una amplia variedad de poblaciones de pacientes[15].

Los tres dispositivos de diagnóstico se basan en principios de procesamiento de señales, como los que has visto en el curso. Para obtener una señal de calidad, se emplean filtros que eliminan ruidos y artefactos. Luego, se extraen características clave como los intervalos RR y patrones específicos en las ondas ECG. Estos parámetros permiten que algoritmos de clasificación detectan arritmias y eventos cardíacos, como la presencia de marcapasos.

Cabe resaltar que, para lograr esto, estos dispositivos deben ser previamente entrenados mediante el uso de bases de datos extensas y etiquetadas, que permitan a los algoritmos aprender a reconocer patrones normales y anormales en las señales cardíacas. De esta manera, pueden generar diagnósticos precisos. Aquí se puede evidenciar el uso de redes neuronales, que son capaces de mejorar la precisión de la clasificación al aprender de grandes volúmenes de datos.

Al integrar estas tecnologías, los sistemas logran una evaluación continua y precisa de las señales cardíacas, optimizando su uso para la atención médica y facilitando la detección temprana de condiciones críticas.

9. Conclusiones

1. La herramienta NeuroKit permite obtener, de manera sencilla, datos específicos sobre las señales de ECG, los cuales son esenciales para realizar operaciones y extraer parámetros relevantes. Estos parámetros, una vez procesados, se utilizan para entrenar redes neuronales, permitiendo que, a través de la diferenciación de estos datos, el modelo sea capaz de clasificar diversas patologías cardíacas con precisión.

2. La extracción de características es un paso crucial antes de la aplicación de cualquier modelo de clasificación, una extracción efectiva permite identificar cuales características están más relacionadas con las salidas que se desean predecir.

3. La identificación de un modelo efectivo permite tener una precisión alta en las predicciones del modelo, ya que según el problema, es mejor tener un modelo supervisado o uno no supervisado.

4. En el ámbito médico las métricas de desempeño son cruciales a la hora de elegir un modelo ya desarrollado, esto es debido a la alta precisión que se requiere en el ámbito clínico, porque los pacientes pueden depender completamente de la clasificación, y si la clasificación es incorrecta, esto puede generar graves complicaciones en los pacientes a corto o mediano plazo.

Referencias

- [1] «Revisión del tema sobre la fibrilación auricular | Aprenda sobre el corazón». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://www.healio.com/cardiology/learn-the-heart/cardiology-review/topic-reviews/atrial-fibrillation>
- [2] «Qué es la variabilidad de frecuencia cardíaca y su interpretación». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://co.aptaivs.com/articulos/variabilidad-de-la-frecuencia-cardiaca-e-intervalos-rr>
- [3] «Variabilidad de la frecuencia cardíaca como factor predictor de las enfermedades cardiovasculares - ScienceDirect». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://www.sciencedirect.com/science/article/pii/S0120563319300683>
- [4] «Varianza: Qué es, fórmula, ejemplo y cómo se calcula». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://www.questionpro.com/blog/es/varianza/>
- [5] «Determinación de la frecuencia cardíaca | Conozca el corazón». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://www.healio.com/cardiology/learn-the-heart/ecg-review/ecg-interpretation-tutorial/determining-rate>
- [6] L. M. Westergaard *et al.*, «Ventricular rate in atrial fibrillation and the risk of heart failure and death», *Europace*, vol. 25, n.º 5, p. euad088, abr. 2023, doi: 10.1093/europace/euad088.
- [7] D. Gross, «The auricular T wave and its correlation to the cardiac rate and to the P wave», *Am. Heart J.*, vol. 50, n.º 1, pp. 24-37, jul. 1955, doi: 10.1016/0002-8703(55)90251-9.
- [8] «[PDF] Dispersión de la Onda P, uso del método manual de medición como recomendación para la práctica médica. Experiencia del Cardiocentro “Ernesto Che Guevara” | Académico semántico». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://www.semanticscholar.org/paper/Dispersi%C3%B3n-de-la-Onda-P%2C-uso-del-m%C3%A9todo-manual-de-Gonz%C3%A1lez-Puerta/240d3df2b0e6ffb1def0eb4447a90f7616231be1>
- [9] «filtros.pdf». Accedido: 29 de octubre de 2024. [En línea]. Disponible en:

- <https://www.pablocetta.com/pdfs/publicaciones/filtros.pdf>
- [10] «¿Qué es onda P? Diccionario médico. Clínica U. Navarra». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://www.cun.es/diccionario-medico/terminos/onda-p>
- [11] «K-Means Clustering Explained». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://neptune.ai/blog/k-means-clustering>
- [12] «Máquinas de Vector Soporte (Support Vector Machines, SVMs)». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: https://cienciadedatos.net/documentos/34_maquinas_de_vector_soporte_support_vector_machines#Support_Vector_Classifier_o_Soft_Margin_SVM
- [13] «Project information | Zio XT for detecting cardiac arrhythmias | Guidance | NICE». Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://www.nice.org.uk/guidance/indevelopment/gid-mt591>
- [14] «Neo EKG T180 de Lepu Medical», Praxisdienst. Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://www.praxisdienst.es/es/Diagnostico/Diagnostico+especializado/Electrocardiografos/Neo+EKG+T180.html>
- [15] «Philips - Cardiógrafos PageWriter TC30 Cardiógrafo», Philips. Accedido: 29 de noviembre de 2024. [En línea]. Disponible en: <https://www.philips.es/healthcare/product/HC860306/cardigrafos-pagewriter-tc30-cardigrafo>